







# Zintegrowany Program Rozwoju Akademii Górniczo-Hutniczej w Krakowie Nr umowy: POWR.03.05.00-00-Z307/17

# Instrukcja do ćwiczeń laboratoryjnych

Nazwa przedmiotu	Eksploracja danych
Temat ćwiczenia	Hurtownie danych

Poziom studiów	II stopień
Kierunek	Informatyka
Forma i tryb studiów	Studia stacjonarne
Semestr	semestr letni roku akademickiego 2023/2024

mgr inż. Marek Macura



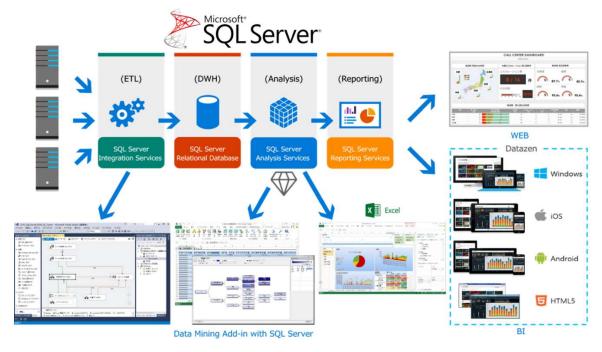
Wydział Informatyki, Elektroniki i Telekomunikacji

### Cel ćwiczenia

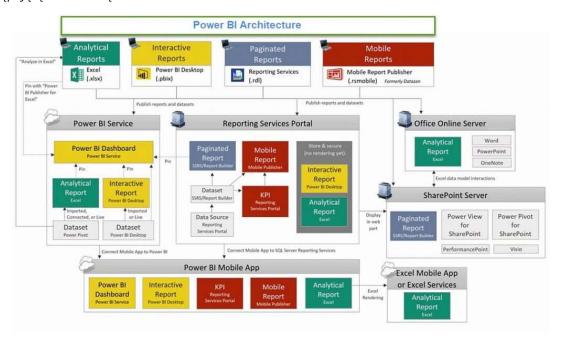
Zapoznanie się z zapytaniami analitycznymi, budową struktur hurtowni danych, analizą danych z wykorzystaniem języka MDX oraz raportowaniem w MS SQL Server 2017 i MS Power BI.

## Wprowadzenie do ćwiczenia

Wymaganymi wiadomościami wstępnymi z wykładu są: rozszerzenia SQL wspierające analizy, podstawowe pojęcia modelu wielowymiarowego (fakty, miary, wymiary i ich hierarchie, kostki), modelowanie ROLAP (schemat gwiazdy, płatka śniegu), język MDX. Dodatkowo wymagana jest znajomość modelowania danych według modelu relacyjnego. Pakiet SQL Server 2017 zawiera pełne zestawienie usług analityki biznesowej (business intelligence) umożliwiając realizację procesu okrywania wiedzy z danych w zakresie/na potrzeby biznesowe.



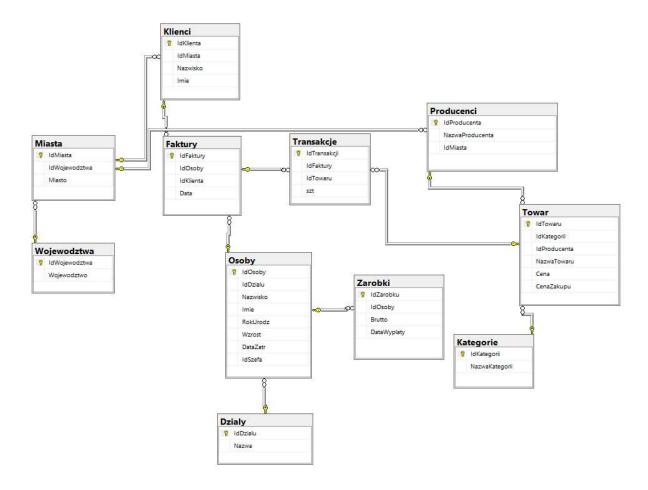
W ramach ćwiczenia pokazane zostanie, jak zbudować struktury hurtowni danych oraz kostki analityczne, które stanowią bazę pod raportowanie i inne metody analityczne. Instrukcje zawierają w tym zakresie także zadania do samodzielnego wykonania. Podobnie przedstawiony został obszar konsumencki odnosząc się do języka dostępowego MDX (Multidimensional Expressions) oraz oprogramowania Power BI typu self-service z następującą architekturą:



## Plan/ program ćwiczenia

- 1. Zapoznanie się z treningową bazą danych, która opisuje działalność firmy handlowej.
  - 1.1. Uruchom Microsoft SQL Server Management Studio 18 i połącz się z lokalnym silnikiem bazy danych.
  - 1.2. Wybierz bazę "BazaRelacyjna" i zapoznaj się z diagramem DIAGRAM1 tej bazy.

Firma sprzedaje towary, które są sklasyfikowane według kategorii. Towary kupują klienci mieszkający w miejscowościach. Przy każdym zakupie wystawiana jest faktura, na której w przypadku zakupu pewnej ilości jednego typu towaru definiuje się transakcję. Na fakturze może pojawić się wiele transakcji. Każda faktura jest wystawiana przez pracownika firmy, przypisanego do konkretnego działu. Każdy z pracowników otrzymuje wiele różnego rodzaju wypłat.



#### 2. Zapytania analityczne

2.1. Zapytanie wyznaczające sumy wypłat brutto dla każdego z pracowników firmy, wyświetlając obok nazwę działu ma następującą postać:

```
SELECT Nazwa, Nazwisko, SUM(Brutto)

FROM Dzialy JOIN Osoby

ON Dzialy.IdDzialu = Osoby.IdDzialu

JOIN Zarobki

ON Osoby.IdOsoby = Zarobki.IdOsoby

GROUP BY Nazwa, Nazwisko, Osoby.IdOsoby;
```

Poziom obliczania sumy jest wyznaczony przez najmniejszy poziom w hierarchii zawarty w klauzuli *GROUP BY*.

2.2. Jeżeli po poleceniu SELECT ograniczymy się tylko do pola Nazwa to możemy w GROUP BY także ograniczyć się do tego samego pola. Podsumowanie będzie wykonywane dla każdego działu – wszystkich jego pracowników. Zmiana opcji grupowania pociąga za sobą zmianę poziomu wyznaczania funkcji agregujących. Nie możliwe jest wyznaczenie podsumowania na dwóch poziomach za pomocą pojedynczego zapytania wybierającego, używającego tej klauzuli. Rozwiązaniem jest zastosowanie podzapytania wyznaczającego podsumowanie na poziomie działów i połączenie go (operator JOIN) z zapytaniem głównym, które oblicza sumę dla każdego z pracowników:

```
SELECT Nazwa, Nazwisko, SUM(Brutto) AS Razem, SD
FROM Dzialy JOIN Osoby
ON Dzialy.IdDzialu = Osoby.IdDzialu
JOIN Zarobki
ON Osoby.IdOsoby = Zarobki.IdOsoby
JOIN
(SELECT IdDzialu, SUM(Brutto) AS SD
FROM Osoby JOIN Zarobki
ON Osoby.IdOsoby = Zarobki.IdOsoby
GROUP BY IdDzialu) AS xxx
ON Dzialy.IdDzialu=xxx.IdDzialu
GROUP BY Nazwa, Nazwisko,Osoby.IdOsoby, SD;
```

Przez analogię dla trzech poziomów konieczne jest zastosowanie poza zapytaniem głównym dwóch podzapytań, a dla czterech poziomów trzech itd.

2.3. Pierwszym wariantem upraszczającym jest operator *ROLLUP*, który wylicza podsumowania na wszystkich poziomach wymienionych, jako argument grupowania i dodaje podsumowanie dla pełnego zestawu rekordów. Przykładem jest wyznaczenie wszystkich podsumowań brutto:

```
SELECT Nazwa, Nazwisko, SUM(Brutto) AS Razem
FROM Działy JOIN Osoby
ON Działy.IdDziału = Osoby.IdDziału
JOIN Zarobki
ON Osoby.IdOsoby = Zarobki.IdOsoby
GROUP BY Nazwa, Nazwisko
WITH ROLLUP;
```

2.4. Kolejnym przykładem jest zastosowanie operatora CUBE, który stanowi rozszerzenie ROLLUP:

```
SELECT Nazwa, Nazwisko, SUM(Brutto) AS Razem
FROM Dzialy JOIN Osoby
ON Dzialy.IdDzialu = Osoby.IdDzialu
JOIN Zarobki
ON Osoby.IdOsoby = Zarobki.IdOsoby
GROUP BY Nazwa, Nazwisko
WITH CUBE
ORDER BY Nazwa,Nazwisko;
```

Rezultatem jest rozszerzenie poprzedniego wyniku o podsumowania dla pracowników z odseparowaniem informacji od nazw działów, w których pracują.

2.5. Następnym elementem jest operator GROUPINGS SETS. Powoduje on, że sumy wyznaczane są na obu poziomach, wskazanych parametrami grupowania. W obu przypadkach informacja jest odseparowana od informacji z drugiego z poziomów. Ciekawą cechą tego operatora jest możliwość łączenia atrybutów:

SELECT Wojewodztwo, Miasto, NazwaProducenta, NazwaTowaru, SUM(cena\*szt) AS Wartosc

FROM Wojewodztwa

JOIN Miasta ON Wojewodztwa.IdWojewodztwa=Miasta.IdWojewodztwa

JOIN Producenci ON Miasta.IdMiasta=Producenci.IdMiasta

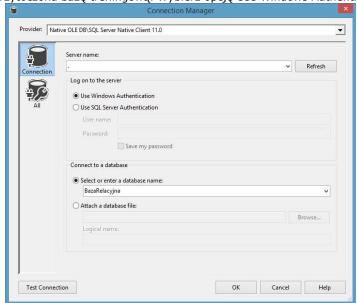
JOIN Towar ON Producenci.IdProducenta=Towar.IdProducenta

JOIN Transakcje ON Towar.IdTowaru=Transakcje.IdTowaru

GROUP BY GROUPING SETS ((Wojewodztwo, Miasto), (Nazwa Producenta, Nazwa Towaru));

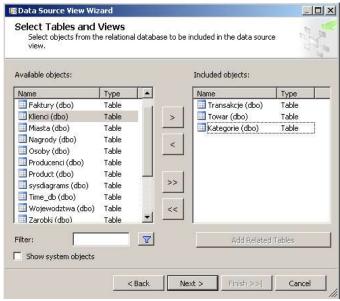
#### 3. Tworzenie elementów hurtowni danych

- 3.1. Proszę zapoznać się z widokami: "Wszystkie\_transakcje" oraz "czas".
- 3.2. Uruchom Visual Studio 2017 (SSDT) i stwórz nowy projekt typu Analysis Services.
- 3.3. Pierwszym krokiem tworzenia struktur analitycznych OLAP jest definicja źródła danych. Kliknij prawym na Data Sources w Solution Explorer. Dodaj nowe źródło zostawiając domyślny Provider, serwer lokalny i przytoczona bazę treningową. Wybierz opcję Use Windows Authentication.



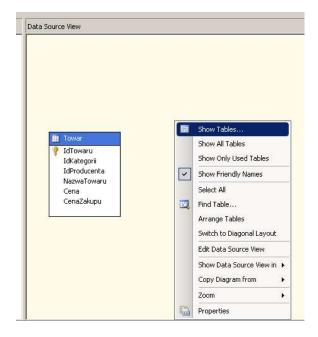
Zaznacz utworzone połączenie a następnie wybierz opcję "Use the service account"

3.4. Kolejnym krokiem jest utworzenie perspektywy źródła danych (prawym na Data Source Views w Solution Explorer). Wybieramy zdefiniowane już źródło a w kolejnym etapie wybieramy tabele i perspektywy źródłowe do realizacji pozostałych elementów (należy pamiętać, że powinny one zapewniać możliwość zdefiniowania co najmniej jednego wymiaru oraz tabeli faktów). Rozpoczniemy od minimalistycznego podejścia tj. wyboru trzech tabel: Towar i Kategorie jako wymiary oraz Transakcje jako tabela faktów:



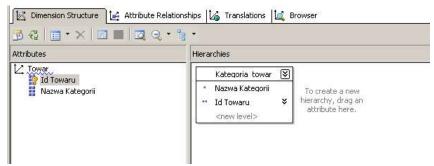
Po zakończeniu kreatora mamy dostępną graficzna prezentację tworzonej struktury. Zwrot strzałki wskazuje tabele będąco w relacji "jeden do wielu" po stronie jeden.

3.5. Przejdźmy do tworzenia właściwych elementów hurtowni, rozpoczynając od wymiarów (Dimension w Solution Explorer). Zaznaczamy "Use an existing table" następnie zaznaczamy tabele, która definiuje najniższy poziom w hierarchii, a jednocześnie jest bezpośrednio połączona z tabela faktów. Będzie to tabela Towar. Wybierz ją oraz IdTowaru jako klucz wymiaru oraz atrybut NazwaTowaru jako nazwę kolumny. Odznacz related tables i zaznacz tylko Id Towaru w available attributes. Zakładka Dimension Structure w oknie edycyjnym reprezentuje strukturę wymiaru. Aby możliwe było obejrzenie rzeczywistych danych wymiar musi zostać najpierw przetworzony (ikona Process, podobna do znaku recyklingu). Takie przetworzenie jest konieczne zarówno bezpośrednio po zdefiniowaniu obiektu, jak i po każdej modyfikacji struktury logicznej. Po przetworzeniu elementu konieczne jest ręczne wymuszenie odświeżania (Reconnect) w zakładce Browser gdzie możliwe jest obejrzenie przetworzonej struktury. Dla każdego nawet najprostszego wymiaru tworzony jest element korzenia All, reprezentujący wszystkie wartości poziomu poniżej – wszystkie towary. Aby dodać kolejne atrybuty czy poziomy hierarchii, musimy przedtem dodać definicje kolejnych tabel (zakładka Dimension Structure). Wybieramy pozycję Show Tables, dostępna w menu podręcznym, gdzie zaznaczamy tabelę Kategorie, która stanowi poziom nadrzędny do już istniejącego:



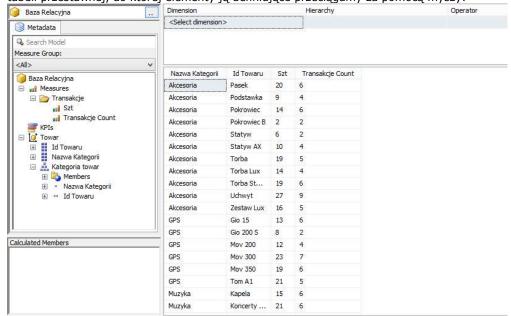
Po dodaniu tabeli pole NazwaKategorii (definiującej kolejny atrybut) należy przeciągnąć z definicji widoku do panelu Attributes. Po przetworzeniu i odświeżeniu dostępne są struktury dla obu atrybutów (zakładka Browser). Aby zbudować strukturę wielopoziomową należy utworzyć hierarchię w panelu

Hierarchies (metodą "przeciągnij i upuść"). Zaczynamy od atrybutu najogólniejszego do atrybutu najbardziej szczegółowego oraz nadajemy nazwę hierarchii "Kategoria\_towar":



Po przetworzeniu poza płaskimi strukturami mamy widoczna strukturę o dwóch poziomach.

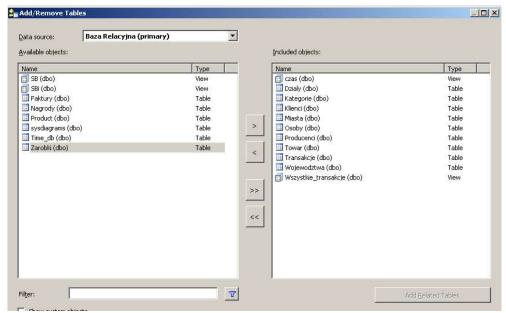
3.6. Przejdźmy do definicji kostki. Podobnie jak poprzednio uruchamiamy kreatora (Cubes w Solution Explorer). Wybieramy "Use existing tables", wskazujemy tabele faktów (Transakcje), wybieramy miary dla kostki (Szt, Transakcje Count) oraz wskazujemy wymiary, które będą wchodziły do definicji kostki (Towar). Tabela faktów jest zaznaczona na żółto a tabele wymiarów na niebiesko. Po przetworzeniu możliwe jest obejrzenie wartości miar zgodnie z zdefiniowanymi atrybutami wymiarów w zakładce Broswer. Lewy panel zawiera logiczna definicje kostki – miary i wymiary. Prawy jest formą tabeli przestawnej, do której elementy ją definiujące przeciągamy za pomocą myszy:



#### 4. Modyfikacja struktury hurtowni danych

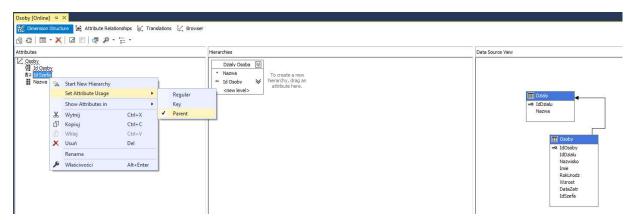
Pomímo pełnej funkcjonalności utworzonych wcześniej struktur spróbujmy utworzyć bardziej złożone rozwiązanie.

4.1. Pierwszym krokiem jest zmiana danych definiujących perspektywę źródła. W edytorze graficznym korzystamy z opcji "Add/Remove Tables" menu kontekstowego. Przeniesiemy pewne obiekty tak jak zostało to pokazane na rysunku:

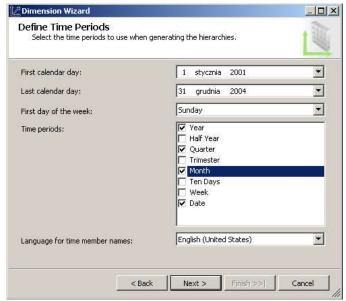


Ponieważ dla perspektyw nie są definiowane klucze obce, oba zaimportowane obiekty tego typu nie są połączone z żadnym z pozostałych. Dodajmy relacje między tabelą faktów (perspektywa Wszystkie\_transakcje) a pozostałymi elementami wykorzystując pola identyfikatorów (IdTowaru, IdOsoby, IdKlienta). Realizujemy to przeciągając odpowiednie pola tabeli faktów do pól kluczy głównych innych tabel. Perspektywę czas łączymy względem pola DataNum, które zawiera datę przekształconą na liczbę.

4.2. Utwórz wymiar opierający się na tabeli Osoby. Atrybut IdSzefa ustala hierarchie podporzadkowania. Dlatego należy zmienić sposób użycia tego atrybutu z Regular na Parent.

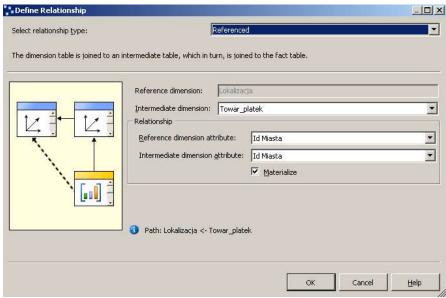


- 4.3. Utwórz wymiar czasu, gdzie atrybutami wymiaru są wszystkie pola widoku reprezentujące rok, kwartał, miesiąc i datę. Utwórz także hierarchię Rok\_kwartal\_miesiac.
- 4.4. Po utworzeniu wymiarów zrealizuj kostkę o nazwie **Zyski** zawierającą wymiary: Towar, Osoby oraz Czas oraz wszystkie miary a następnie przedstaw wyniki dla wymiarów Czas i Towar oraz miar Wartosc i Ilosc. Możliwe jest także utworzenie wymiaru czasowego na bazie szablonu. W kreatorze wymiaru wybieramy opcję "Generate a time table on the server" następnie uzupełniamy odpowiednie wartości tak jak na rysunku:



Zaznaczamy opcję "Regular calendar". Po utworzeniu wymiaru należy go dodać do kostki (opcja "Add Cube Dimension") oraz połączenie go z tabelą faktów. Połączenie realizujemy w zakładce Dimension Usage. Tylko wymiar Time nie jest połączony. Po uruchomieniu kreatora definicji relacji zaznaczamy typ relacji Regular, Granularity attribute: Date a w tabelce Relationship w kolumnie Measure Group Columns wybieramy pole DataNum. Przedstaw te same wyniki wykorzystując wymiar Time.

- 4.5. Utwórz wymiar Klienci, który pozwala określić lokalizacje każdego klienta na dwóch poziomach hierarchii (Wojewodztwo, Miasto) oraz dane personalne ograniczone do nazwiska.
- 4.6. Utwórz dwupoziomową hierarchię opisującą przyporządkowanie pracowników firmy (tabela Osoby) do struktury organizacyjnej (tabela Dzialy)
- 4.7. Rozszerz wymiar Towar poprzez dodanie trzech tabel definiujących producenta towaru oraz lokalizacje geograficzna firmy (Miasta, Wojwodztwa). Dodaj rozbudowana hierarchię woj\_miasto\_prod\_towar wykorzystującą atrybuty z dodanych tabel. Zmień nazwę wymiaru na Towar\_calosc.
- 4.8. Przedstaw wyniki nowej kostki dla tych samych miar co wcześniej oraz wymiarów Klient i Towar\_calosc.
- 4.9. Utwórz kostkę o strukturze płatka śniegu. Dwa wymiary (opisujące towary i klientów) mają wspólną część (tabele: Miasta i Wojewodztwa). Można ten fragment generować oddzielnie i dołączać do pozostałych atrybutów definiujących wymiar. Utwórz niezależny wymiar Lokalizacja z tabel: Wojewodztwa, Miasta oraz hierarchię z atrybutami IdMiasta i Wojewodztwo. Następnie utwórz wymiar Towar\_platek zawierający atrybuty opisujące nazwę towaru i nazwę producenta oraz IdMiasta (klucz obcy, który zostanie wykorzystany do dołączenia wymiaru Lokalizacja). Podobnie utwórz wymiar Klienci\_platek zawierający nazwisko klienta i IdMiasta. Kolejnym krokiem jest utworzenie kostki Zysk\_platek z wcześniejszymi wymiarami. Po jej utworzeniu przechodzimy do zakładki dimension usage a tam tworzymy powiązania z tabelą faktów wymiaru Lokalizacja z wymiarem Towar\_platek i jego kopii z wymiarem Klienci\_platek jak na rysunku:

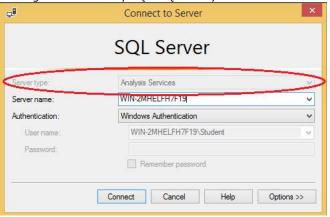


Przedstaw wyniki kostki dla miary Wartosc i wymiarów Klienci\_platek i Towar\_platek z ich połączeniem z wymiarem odpowiadającym lokalizacji. Należy pamiętać, które z hierarchii są ze sobą połączone referencyjnie i tylko te umieszczać w opisie tego samego elementu (kolumny lub wiersza).

#### 5. Analiza danych za pomoca MDX

Możemy manipulować elementami hurtowni danych, wykorzystując język zapytań wielowymiarowych MDX (Multidimensional extension). Do tego celu można użyć narzędzia SQL Server Management Studio.

5.1. Uruchom SQL Server Management Studio i połącz się z Analysis Services:



Po połączeniu naciśnij przycisk New Query. Wybierz stworzony wcześniej projekt BI i wybierz kostkę Zyski.

5.2. Dość elementarnym zapytaniem MDX jest zapytanie wyświetlające wartości wszystkich miar dla kostki:

SELECT [Measures].[Wartosc] ON COLUMNS FROM [Zyski];

5.3. Wyświetlenie wszystkich członów dla danego atrybutu wymiaru lub miary uzyskujemy dzięki zastosowaniu metody members:

SELECT [Towar\_calosc].[Nazwa kategorii].members ON ROWS, [Measures].[Wartosc] ON COLUMNS FROM [Zyski];

5.4. Kolejny przykład obrazuje wyświetlanie zestawu atrybutów – zbioru Set. Jego definicja ujęta jest w nawiasy klamrowe i oddzielone przecinkami. Metoda children zwraca wszystkie człony podrzędnego poziomu wskazanego atrybutu hierarchii:

SELECT Measures. Members ON COLUMNS,

{[Towar\_calosc].[Kategoria\_towar].[Nazwa Kategorii].[GPS].Children,

```
[Towar_calosc].[Kategoria_towar].[Nazwa Kategorii].[Muzyka]. Children} ON ROWS FROM [Zyski];
```

5.5. Możliwe jest zastosowanie w definicji zestawu atrybutów wskazanego człona poziomu nadrzędnego oraz wszystkich jego dzieci. W tym celu można użyć wcześniejszej metody children lub funkcji DESCENDANTS():

SELECT Measures.Members ON COLUMNS, {[Towar\_calosc].[Kategoria\_towar].[Nazwa Kategorii]. [GPS],

DESCENDANTS ([Towar\_calosc].[Kategoria\_towar].[Nazwa Kategorii].[GPS], [Id Towaru])} ON ROWS FROM [Zyski];

Metoda children pozwala tylko na wyznaczenie węzłów leżących bezpośrednio poniżej wybranego węzła, natomiast funkcja DESCENDANTS umożliwia wyświetlenie potomków leżących w dowolnej odległości od węzła macierzystego.

5.6. MDX umożliwia tworzenie miar ad hoc. Miary te są realizowane w sekcji WITH. Definicję rozpoczyna słowo kluczowe MEMBER, po którym określa się nazwę kwalifikowaną miary a po słowie kluczowym AS następuje właściwa definicja:

```
WITH MEMBER Measures.ZyskProc AS

([Measures].[Wartosc]-[Measures].[Wartosc Zakupu]) /

[Measures].[Wartosc Zakupu], FORMAT_STRING = '#.00%'

SELECT

NONEMPTY([Towar_calosc].[Nazwa kategorii].members) ON COLUMNS,

NONEMPTY([Klienci].[Id Wojewodztwa].members) ON ROWS

FROM [Zyski]

WHERE Measures.ZyskProc;
```

5.7. Miary można wyznaczać jako wyrażenia dla różnych elementów i poziomów hierarchii. Możliwe jest wyznaczenie sumy bieżącej przy użyciu złożenia funkcji PERIODTODATE(), pozwalającej na wskazanie atrybutów na dowolnym poziomie wskazywanym pierwszym parametrem oraz funkcji SUM():

```
WITH MEMBER Measures.Zysk_YTD AS

SUM(PERIODSTODATE([Time].[Year - Quarter - Month - Date].[Year],

[Time].[Year - Quarter - Month - Date].CurrentMember), [Wartosc] - [Wartosc Zakupu]),
FORMAT_STRING='#.00'

SELECT

[Towar_calosc].[Nazwa Kategorii].MEMBERS ON COLUMNS,

DESCENDANTS([Time].[Year - Quarter - Month - Date], [Time].[Year - Quarter - Month - Date].
[Month]) ON ROWS

FROM [Zyski]

WHERE Measures.Zysk_YTD;
```

5.8. Analizując wyniki poprzedniego zapytania widać, że występują w niej wartości puste. Nie można się ich pozbyć za pomocą funkcji NONEMPTY() – należy zastosować funkcję FILTER z wyrażeniem określającym, że interesują nas tylko te kolumny, dla których zysk jest różny od null (usuwamy puste kolumny):

```
WITH MEMBER Measures.Zysk_YTD AS

SUM(PERIODSTODATE([Time].[Year - Quarter - Month - Date].[Year],
```

[Time].[Year - Quarter - Month - Date].CurrentMember), [Wartosc] - [Wartosc Zakupu]), FORMAT\_STRING='#.00'

### SELECT FILTER(

[Towar\_calosc].[Nazwa Kategorii].MEMBERS, ([Wartosc] - [Wartosc Zakupu]) <> NULL) ON COLUMNS,

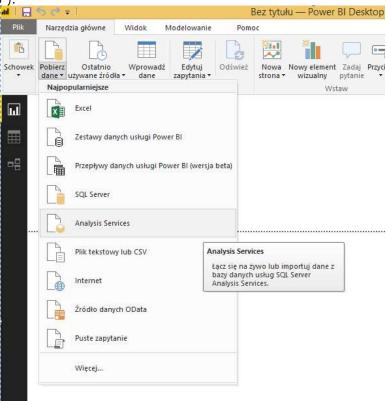
DESCENDANTS([Time].[Year - Quarter - Month - Date], [Time].[Year - Quarter - Month - Date]. [Month]) ON ROWS

FROM [Zyski]

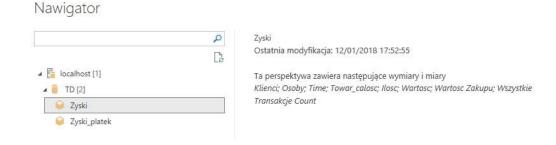
WHERE Measures.Zysk\_YTD;

#### 6. Raportowanie przy użyciu MS Power BI

- 6.1. Możemy manipulować elementami hurtowni danych, aby utworzyć raporty, dashboard'y i interaktywne wizualizacje używając różnych aplikacji klienckich takich jak: Reporting Services, Excel lub Power BI. Ostatnia z nich jest przykładem nowego podejścia do raportowania. Składa się z kilku komponentów, które umożliwiają tworzenie i zarzadzanie interaktywnymi wizualizacjami/dashboard'ami/raportami danych.
- 6.2. Uruchom Power BI Desktop i połącz się z lokalna instancją serwera Analysis Services (wybierz opcje "Połącz na żywo"):

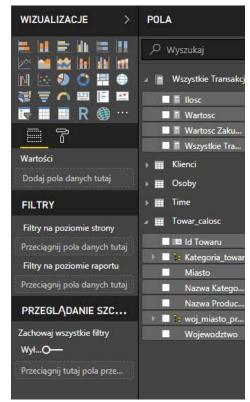


Następnie wybierz kostkę Zyski w oknie nawigatora:



6.3. Utwórz prostą wizualizację tzn. Tabelę przestawną z hierarchią "Kategoria\_towar" oraz dwoma miarami Ilość i Wartość jak na rysunku:





**6.4.** Proszę poeksperymentować z interfejsem tego narzędzia. Spróbować stworzyć inne wizualizacje na bazie innych danych oraz sprawdzić, jak działa przechodzenie względem hierarchii itp.

# Sposób oceny/ uzyskania zaliczenia

Ocenie podlega wiedza z zakresu wykładu w formie aktywności na laboratoriach oraz zadań dodatkowych do wykonania z wydłużonym terminem według skali ocen zgodnej z regulaminem studiów AGH (3.0 – 5.0).

### Literatura

- W. H. Inmon, Building the Data Warehouse, QED Tech. Pub. Group, 1992
- R. Kimball, The DataWarehouse ETL Toolkit, Wiley Publishing, Inc., 2004
- <a href="https://docs.microsoft.com/pl-pl/sql/sql-server/?view=sql-server-2017">https://docs.microsoft.com/pl-pl/sql/sql-server/?view=sql-server-2017</a>
- https://docs.microsoft.com/en-us/power-bi/
- <a href="https://docs.microsoft.com/en-us/sql/mdx/multidimensional-expressions-mdx-reference?view=sql-server-2017">https://docs.microsoft.com/en-us/sql/mdx/multidimensional-expressions-mdx-reference?view=sql-server-2017</a>